FACULDADE DE
CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE NOVA DE LISBOA

Controlo Inteligente

2º Trabalho

Redes neuronais na identificação e

controlo de um processo térmico

Realizado por:

Daniel Sousa, nº52727

João Carvalho, nº 49341

Índice

Introdução Teórica

As redes neuronais têm algumas parecenças com os neurónios que existem no sistema nervoso humano. O neurónio "artificial" é composto por *i* entradas,U_i (ou potenciais de ação), a que estão associados pesos (ou coesão das ligações sinápticas) W_i. A função ativação,$\sigma(.)$,do neurónio devolve a sua resposta, tendo como parâmetro de entrada a soma ponderada das entradas e a polaridade, *b*. Alterando estes valores, esta arquitetura permite-nos modelar sistemas não lineares e têm a capacidade de processar informação em paralelo. A figura abaixo ilustra a estrutura de um neurónio.

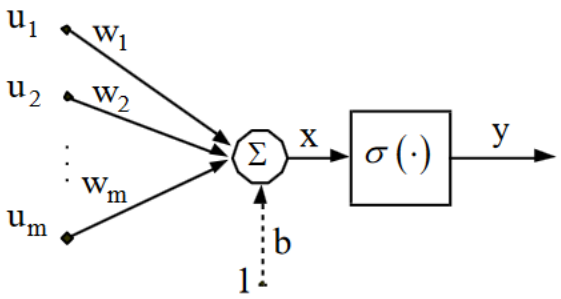

$$\begin{cases} x = \sum_{i=1}^{m} w_i u_i + b \\ y = \sigma(x) \end{cases}$$

Figura 1- Neurónio artificial

Uma rede neuronal é formada por vários neurónios, tendo uma camada de entrada e outra de saída:

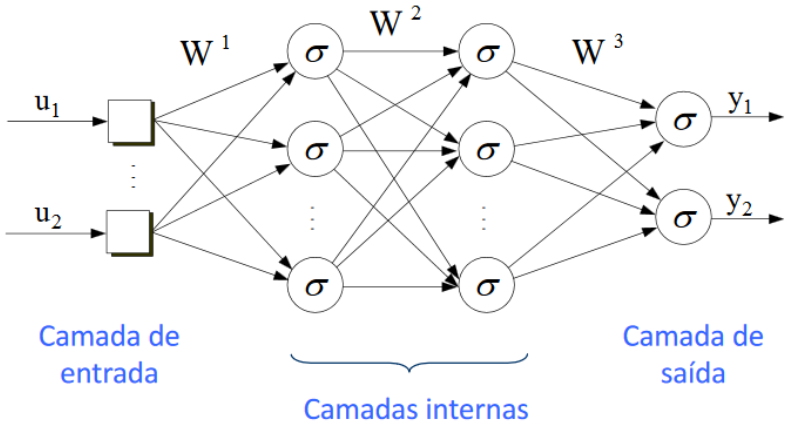

Figura 2- Rede Neuronal

De forma a incorporar informação temporal na rede neuronal, podemos utilizar o vetor de regressão associado ao modelo NARX (*Nonlinear AutoRegressive with eXogenous input*). Desta forma a saída da rede neuronal vai ser uma função que tem como argumento o vetor de regressão.

$$y(k) = f\left(y(k-1), y(k-2), \cdots, y(k-n_a), u(k-1), u(k-2), \cdots, u(k-n_b)\right)$$

Os parâmetros da rede neuronal são treinados de forma a minimizar o erro entre a saída da rede e a saída do processo a modelar.

As arquiteturas de controlo neuronal utilizadas neste trabalho foram:

- Controlo Neuronal Inverso Direto;
- Controlo por modelo interno (*IMC*);

Figura 3- Modelo do controlador neuronal Inverso Direto

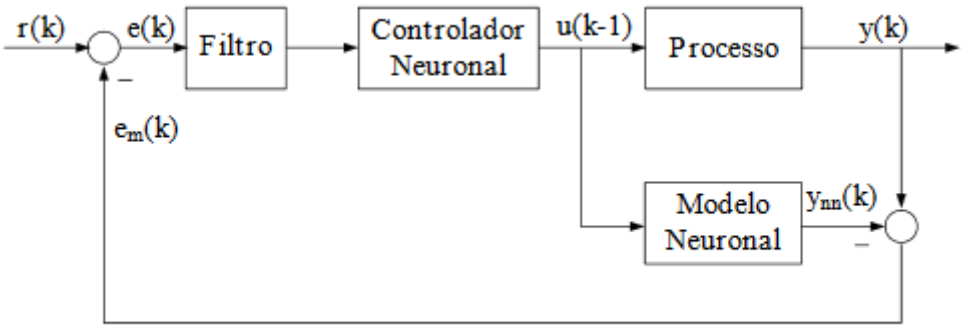

Figura 4- Modelo do controlador neuronal IMC

O filtro presente nos dois modelos é um filtro passa-baixo com ganho estático unitário. É utilizado de forma a evitar variações bruscas ou do controlador neuronal, no caso da figura 3, ou do erro e(k) do controlador IMC.

Durante a resolução deste trabalho, utilizámos, no modelo *IMC*, um filtro depois do controlador neuronal, e não antes deste.

A função transferência de um filtro de primeira ordem é dado por:

$$H_f(q^{-1}) = \frac{1-a}{1-a*q^{-1}}$$

Sendo 1/a a localização pretendida do pólo do filtro.

Aquisição dos dados

Através de um script, disponibilizado pelo professor, obtiveram-se dois conjuntos de dados. Um de estimação e outro de validação. Estes dados retratavam a resposta do sistema a um conjunto de valores de entrada, obtidos aleatoriamente, de 500 amostras com valores pertencentes ao intervalo: [2,0;5,0] V.

Treino da rede do sistema

No treino da rede neuronal, após vários treinos com redes de 3 camadas com um número diferente de neurónios, optou-se por uma rede com 4 neurónios (que era o número mínimo pedido) na camada interna. Isto porque, para além do erro associado a cada rede, também tivemos em conta a especialização da rede, que aumenta com o número de neurónios. Quanto mais especializada for uma rede, menor a sua capacidade de representar o comportamento do sistema para conjuntos de dados diferentes àqueles de treino. O código utilizado neste capítulo está em Anexos sobre o nome de *treino_modelo.mat*.

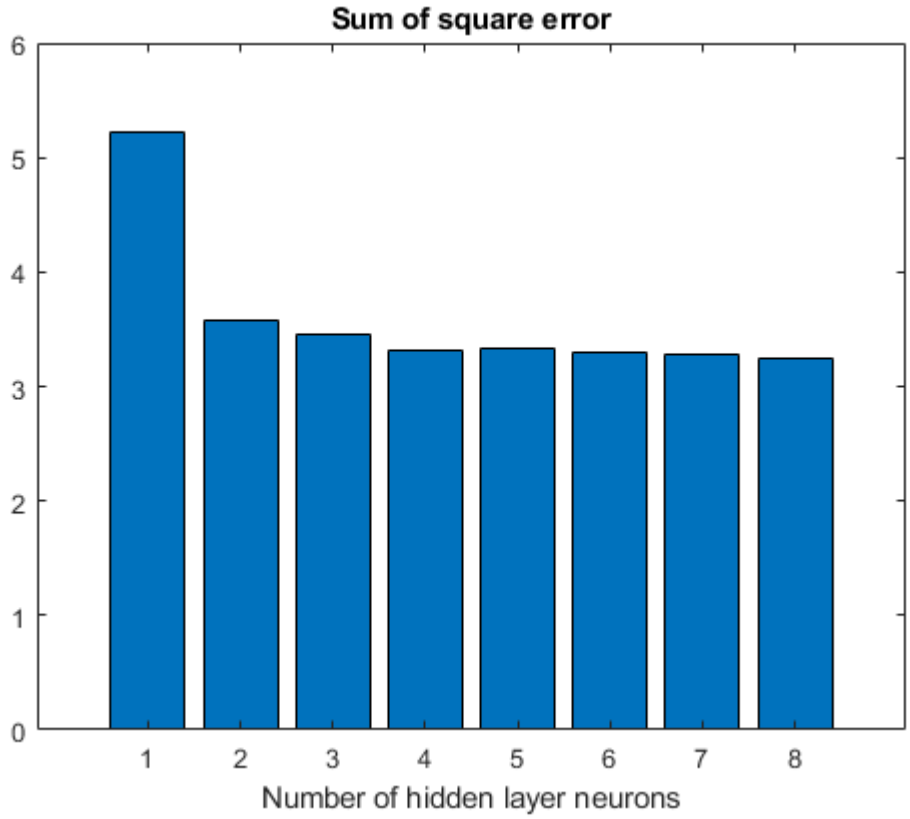

Figura 5- Erro quadrático da rede segundo o número de neurónios da camada interna

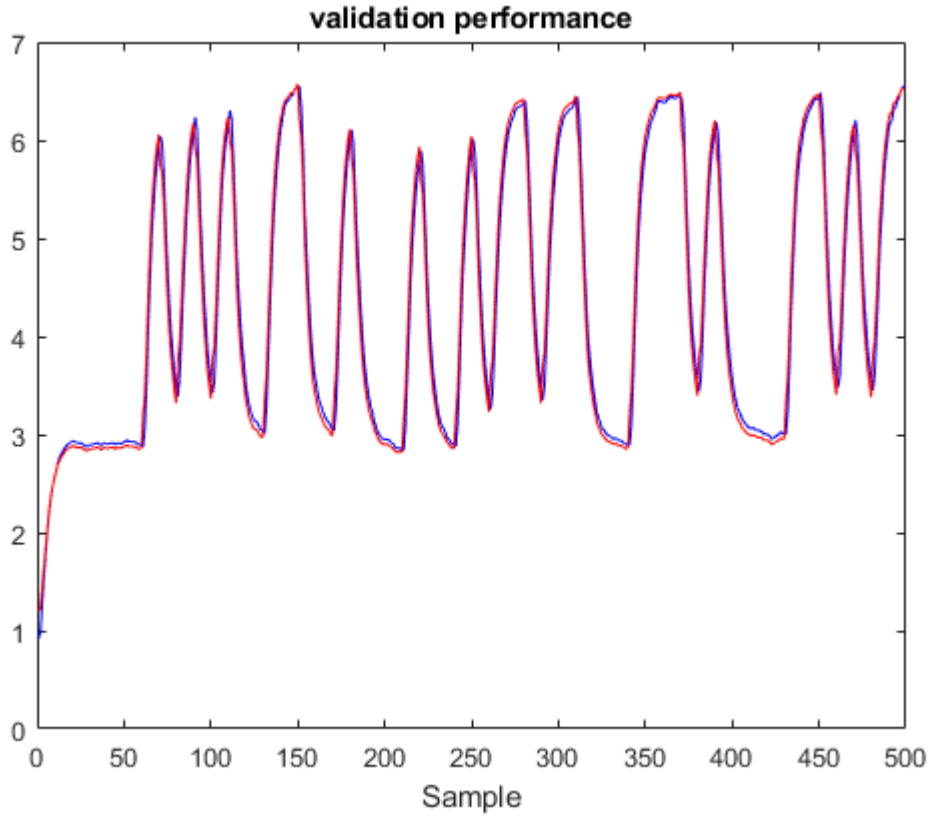

Figura 6- Resposta da rede com os dados de validação

Valor dos pesos e polaridade da rede obtida:

$$W_1 = \begin{bmatrix} 0.6821 & -0.6186 & -0.0602 \\ -0.0001 & 3.9882 & 0.0416 \\ 0.3055 & -0.3527 & 0.0730 \\ 2.1552 & 1.4200 & -0.1865 \end{bmatrix}$$

$$W_2 = [2.1709 \quad 6.8256 \quad 3.0398 \quad 0.2194]$$

$$B_1 = \begin{bmatrix} -3.5399 \\ -7.3229 \\ -0.0004 \\ -12.4762 \end{bmatrix}$$

Comparação com o modelo ARX obtido no laboratório passado

A partir do cálculo do erro quadrático da simulação com os dados de validação, pode se concluir que a rede neuronal é mais próxima ao comportamento do sistema do que o modelo ARX (3,1,2). Isto é, neste caso, a rede neuronal tem um melhor desempenho. O código utilizado neste capítulo está em Anexos sobre o nome de *ARXvsNN.mat*.

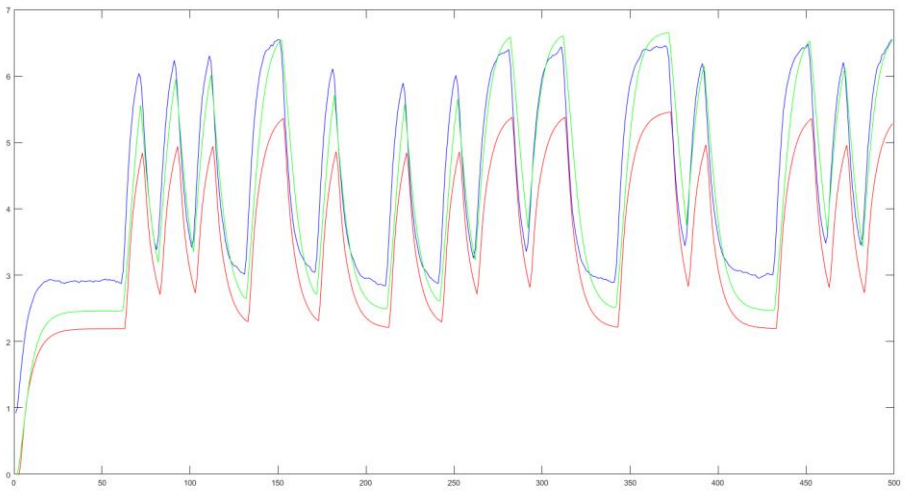

Figura 7- Resposta da rede neuronal e do modelo ARX (3,1,2) – a vermelho o modelo ARX, a verde o modelo neuronal e a azul a saída do processo

Implementação do controlador neuronal

Anteriormente, modelamos as dinâmicas do sistema, ou seja, a maneira como o sistema evolui ao longo do tempo quando este é excitado.

Para modular a ação de controlo foi feito o contrário, utilizou-se o inverso do processo, isto é, com base numa resposta do sistema tentamos chegar à excitação que a provocou. Para tal, usámos uma rede neuronal de 3 camadas internas e treinámo-la com o regressor $\varphi T(k) = [y(k) \;\; y(k-1) \;\; u(k-2)]$, e posteriormente validou se o controlador, ficando então na forma $u(k-1) = f(\varphi(k))$. O código utilizado neste capítulo está em Anexos sobre o nome de *treino_controlador.mat*.

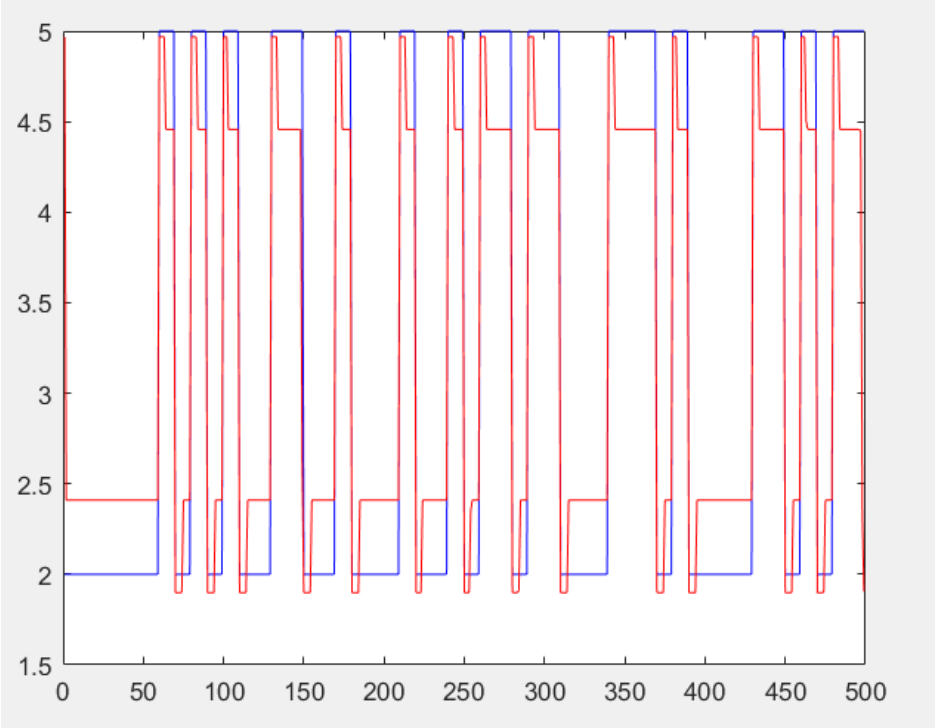

Figura 8 - Resposta do treino do controlador - a azul a referência e a vermelho a ação de controlo.

Simulação

- ## Controlo inverso directo

Para o controlo inverso directo utilizamos o seguinte modelo O código utilizado neste capítulo está em Anexos sobre o nome de *sim_InversoDireto.mat*.

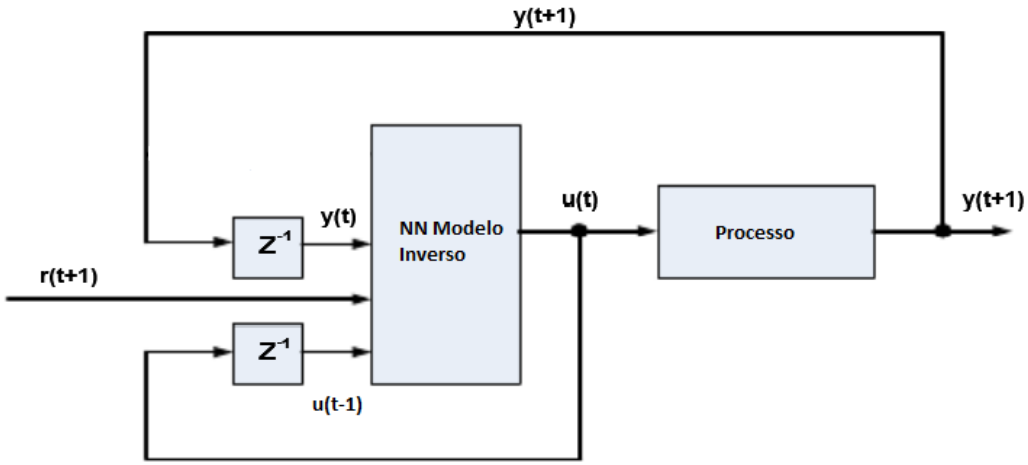

Figura 9- Modelo de controlo inverso directo

Após simularmos com vário valores o filtro de 1ª ordem utilizado foi : $Gf(q^{-1}) = \frac{1+0.4}{1+0.4q^{-1}}$.

Figura 10 - Modelo funcional do controlador inverso directo com filtro passa baixo

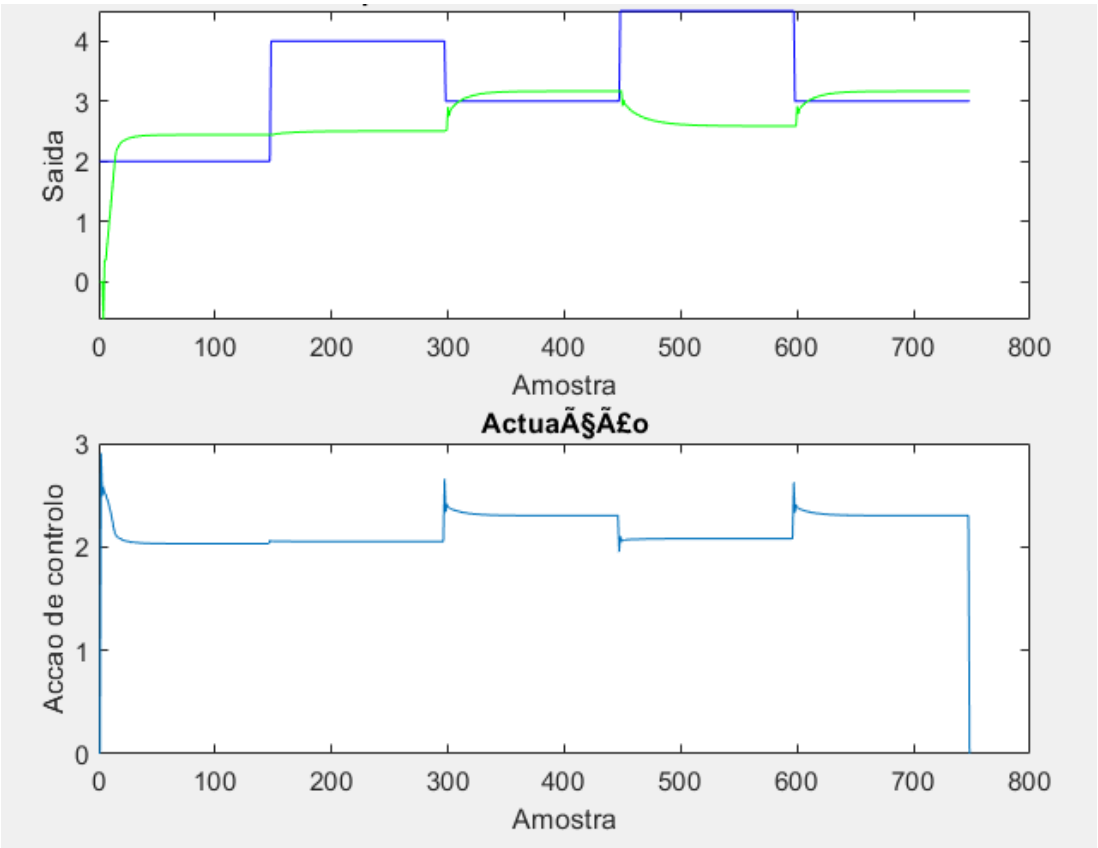

Figura 11 - Resposta em simulação do sistema de controlo neuronal inverso directo- na parte superior a azul está representada a referência, a verde a saída e a azul no gráfico de baixo a ação de controlo.

- Controlo neuronal por modelo interno- IMC

Para a implementação do bloco "Processo" recorremos à aproximação pelo modelo ARX, para este fosse diferente do bloco "Modelo Neuronal", e, desta forma, aproximamo-nos melhor do cenário real em que, por norma, existe um erro entre o modelo neuronal e a resposta do processo. O código utilizado neste capítulo está em Anexos sobre o nome de *sim_IMC.mat*.

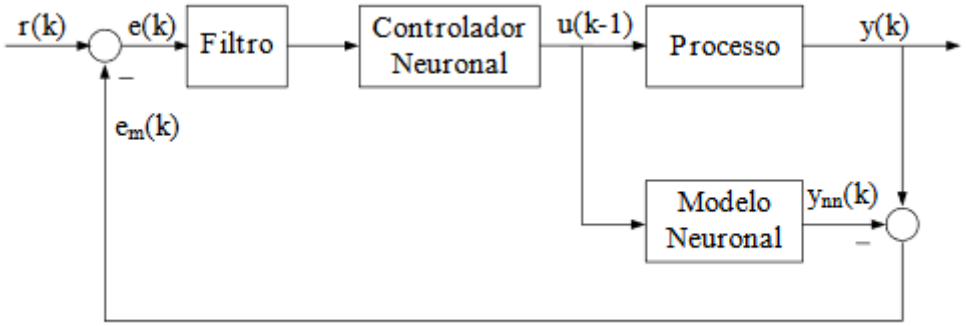

Figura 12- Modelo funcional de controlador neuronal IMC

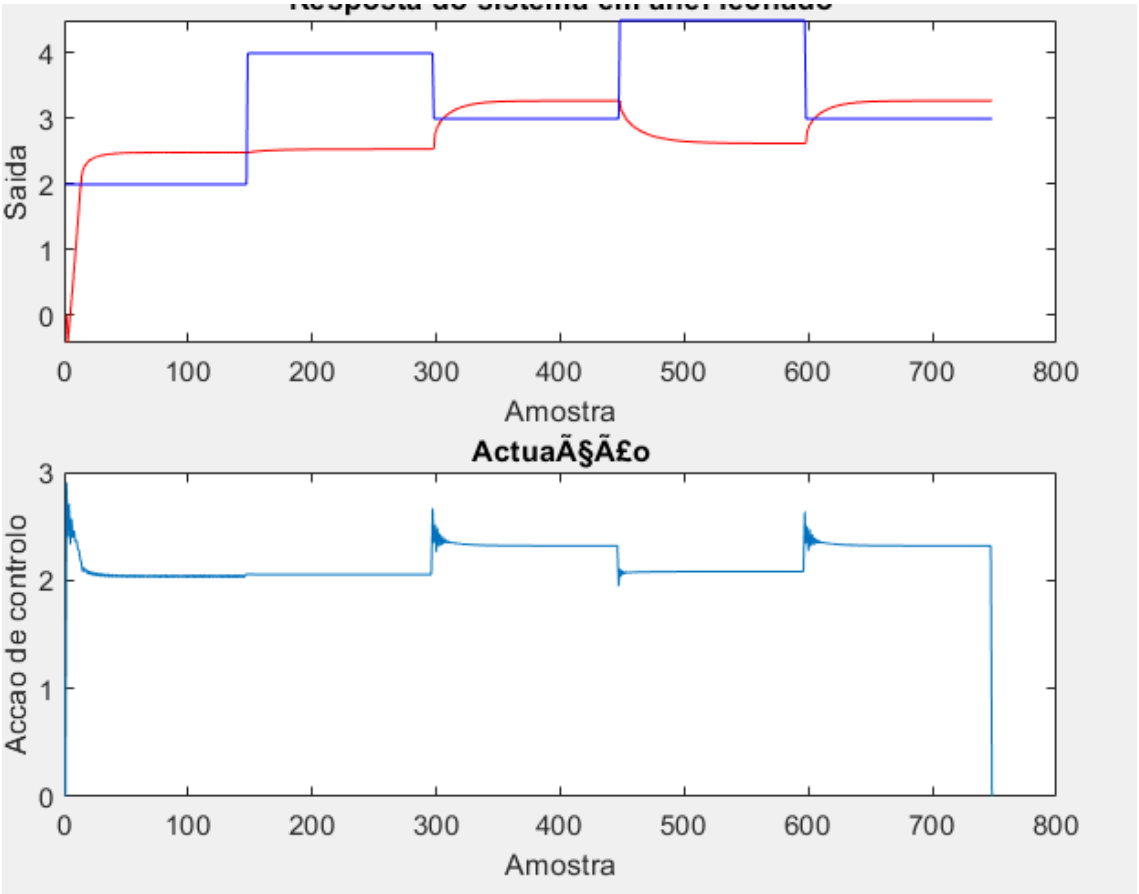

Figura 13 - Resposta em simulação do sistema de controlo IMC- na parte superior a azul está representada a referência, a verde a saída e a azul no gráfico de baixo a ação de controlo.

Controlo do Processo

Depois de se ter simulado a resposta do sistema com os dois topos de controladores, passou-se, efetivamente, ao controlo do processo.

- ## Controlo inverso directo

A resposta obtida era a esperada de acordo com a simulação. Ver figura abaixo. O código utilizado neste capítulo está em Anexos sobre o nome de *ControladorInversoDireto*.mat

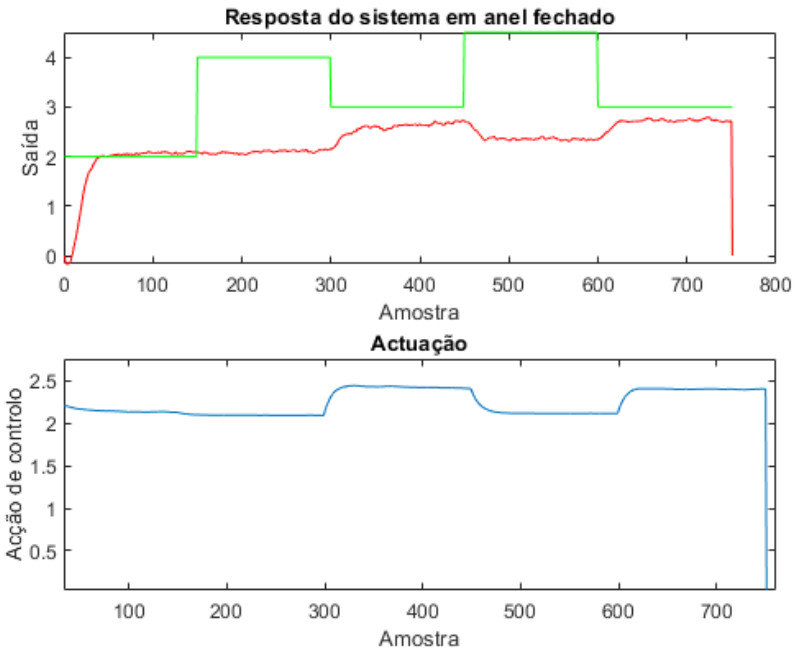

Figura 8- Resposta do processo em modelo inverso direto

- Controlo neuronal por modelo interno- IMC

A resposta obtida do controlador neuronal no modelo IMC era a esperada de acordo com a simulação. Ver figura abaixo. O código utilizado neste capítulo está em Anexos sobre o nome *de ControladorIMC.mat.*

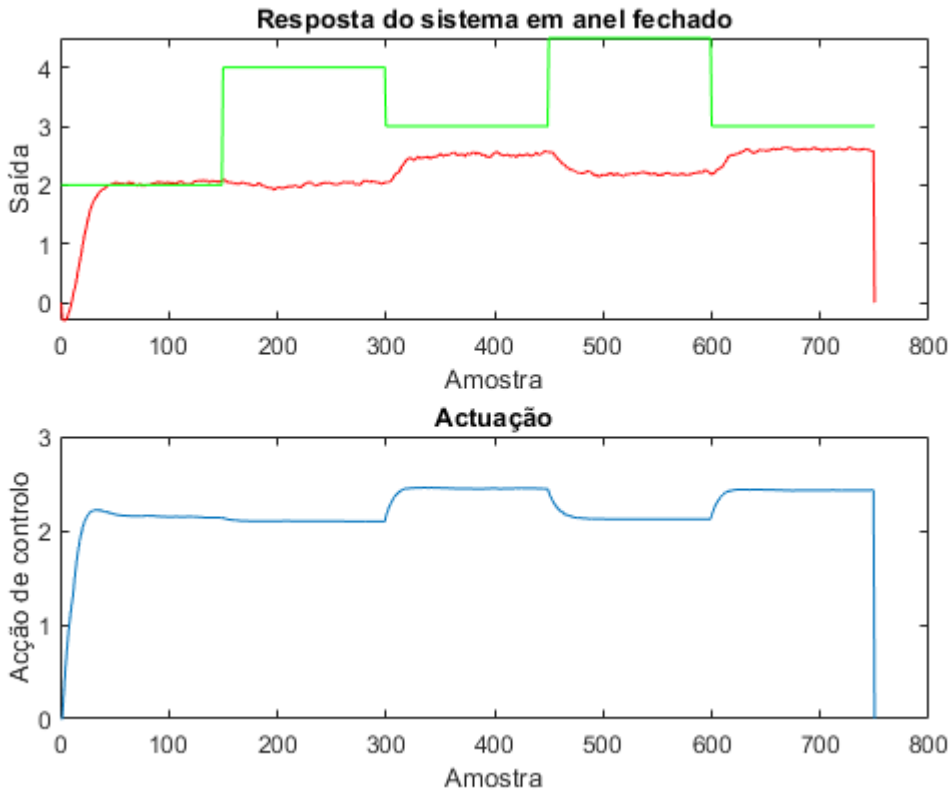

Figura 9- Resposta do processo em modelo interno

Outra Rede Neuronal para o controlador

Ao longo da experiência percebemos que o *matlab* nem sempre treinava as redes da mesma forma, mesmo que com os mesmos dados de estimação. Este pormenor em nada (visível a olho nu) alterou o comportamento do modelo do sistema. Contudo alterou, de forma significativa, o comportamento do controlador. Ver as figuras abaixo.

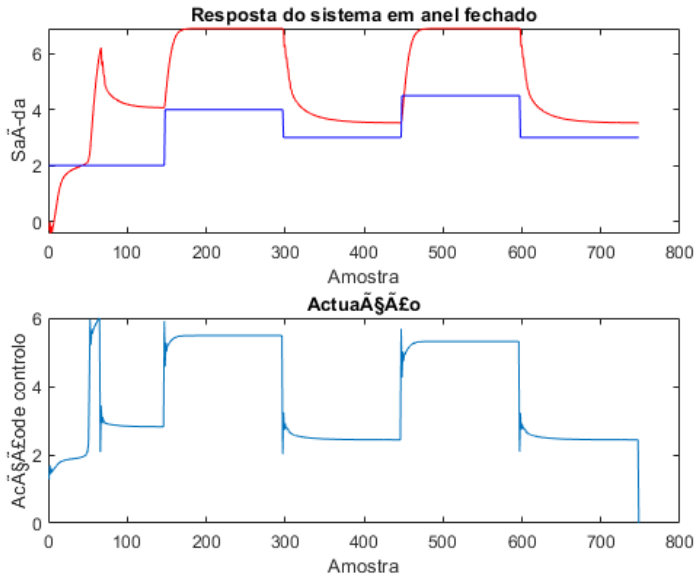

Figura 10- Simulação do modelo ID

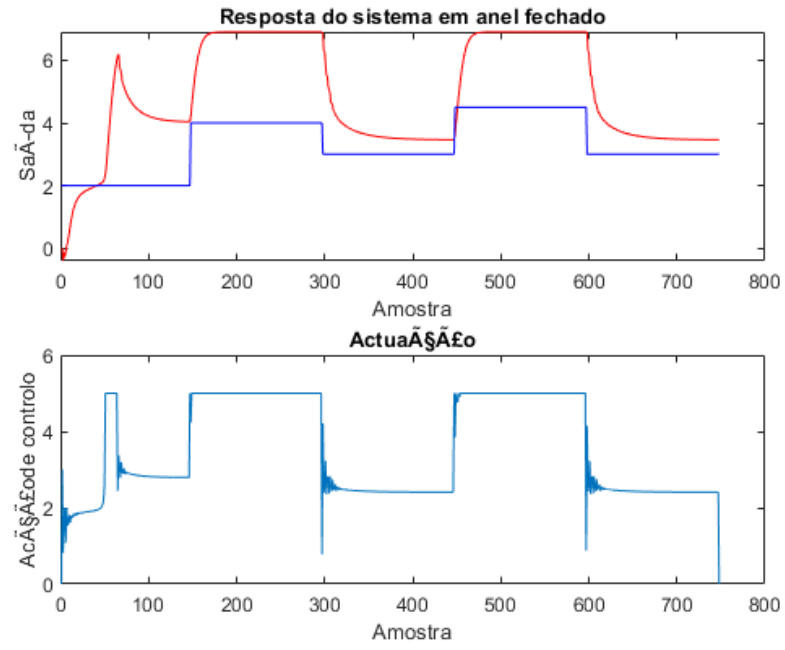

Figura 11- Simulação do modelo IMC

A resposta com este controlador foi pior à obtida com o controlador usado nos capítulos anteriores. Tal como se pode comprovar pela resposta do processo:

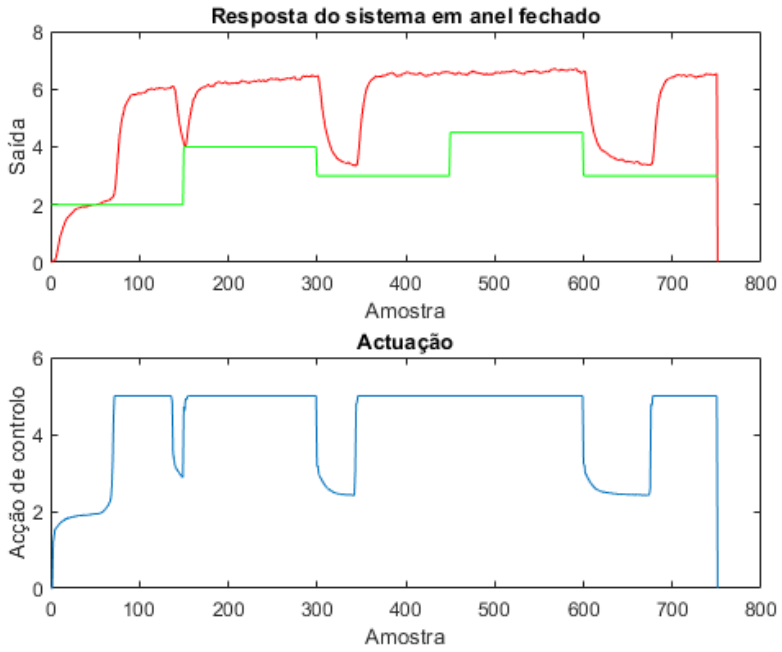

Figura 12- Resposta do sistema com o modelo ID

Conclusão

A resposta do sistema ficou longe do ideal, isto deve-se ao facto das redes neuronais, apesar de representarem o sistema com grande precisão, requerem um grande volume e variedade de dados para a sua eficácia, o que não foi possível devido às circunstâncias. Por isso, obtivemos uma rede, que apesar de representar bem o sistema para dinâmicas semelhantes às de treino, não simulava bem o sistema quando a dinâmica de excitação não era idêntica.

Apesar das redes terem conseguido uma boa aproximação da dinâmica do processo, a ação do controlador ficou muito aquém do esperado. Isto aconteceu devido ao erro das entradas passadas.

Observou-se ainda que o modelo ID teve um desempenho muito parecido com o por Modelo Interno, o que demonstra que a rede neuronal do processo caracteriza o mesmo com qualidade. E como tal o erro, e(k), é praticamente nulo, o que torna o modelo IMC igual ao Inverso Direto.

Anexos

sim_inversoDireto.mat

```
%%% Script para testar o controlador %%%
clear all, close, clc
load ('Nets\net.mat')
load ('NetsC\netc.mat')

load('dataset_prof.mat') % PCT 37-100 (Processo TÃ©rmico)
load processmodel.mat;


 Ref = zeros(1,750);
 Ref(1:150) = 2;
 Ref(150:300) = 4;
 Ref(300:450) = 3;
 Ref(450:600) = 4.5;
 Ref(600:750) = 3;

a=-0.4;
Nmax=length(Ref);
u =zeros(Nmax,1);
uf=zeros(Nmax,1);
y = zeros(Nmax,1);
disp('Em modo controlo!')

for index= 3:Nmax-1
    u(index,1) = sim(netc, [Ref(index+1) y(index,1) u(index-1,1)]');
% Função do controlador
    %u(index,1)=2;
    uf(index,1) = a * uf(index-1,1) + (1-a) * u(index,1);
    uf(index,1) = max(min(uf(index,1),5),0); % SaturaÃ§Ã£o da
excitaÃ§Ã£o
    y(index+1,1) = sim(net,[y(index,1), uf(index,1), uf(index-1,1)]');

end


subplot(2,1,1), plot(y(3:end),'r'), hold on, plot(Ref(3:end),'b'),hold
off,
title('Resposta do sistema em anel fechado')
ylabel('SaÃ-da'), xlabel('Amostra')
subplot(2,1,2), plot(u(3:end))
title('ActuaÃ§Ã£o')
ylabel('AcÃ§Ã£ode controlo'), xlabel('Amostra')
```

sim_IMC.mat

```
%%% Script para testar o controlador %%%
clear all, close, clc
load ('Nets\net.mat')
load ('NetsC\netc.mat')

load('dataset_prof.mat') % PCT 37-100 (Processo TÃ©rmico)


 Ref = zeros(1,750);
 Ref(1:150) = 2;
 Ref(150:300) = 4;
 Ref(300:450) = 3;
 Ref(450:600) = 4.5;
 Ref(600:750) = 3;

%ARX(3,1,2)
A = [ 1 -1.504 0.8344 -0.2358 ];
B = [ 0 0 0.1037];
 erro = 0;

a=-0.4;
Nmax=length(Ref);
u =zeros(Nmax,1);
uf=zeros(Nmax,1);
y = zeros(Nmax,1);
y_process = zeros(Nmax,1);
disp('Em modo controlo!')

for index= 4:Nmax-1
    u(index,1) = sim(netc, [Ref(index+1)-erro y(index,1) u(index-
1,1)]');  % Função do controlador
    uf(index,1) = a * uf(index-1,1) + (1-a) * u(index,1);
    uf(index,1) = max(min(uf(index,1),5),0); % SaturaÃ§Ã£o da
excitaÃ§Ã£o
    y_process(index+1,1) = -A(2)*y(index,1)-A(3)*y(index-1,1) -
A(4)*y(index-2,1) + B(1)*uf(index,1) + B(2)*uf(index-1,1) +
B(3)*uf(index-2,1);
    y(index+1,1) = sim(net,[y(index,1), uf(index,1), uf(index-1,1)]');
    erro = y_process(index+1,1) - y(index+1,1)
end


subplot(2,1,1), plot(y(3:end),'r'), hold on, plot(Ref(3:end),'b'),
plot (y_process(3:end),'g'),hold off,
title('Resposta do sistema em anel fechado')
ylabel('SaÃ-da'), xlabel('Amostra')
subplot(2,1,2), plot(uf(3:end))
title('ActuaÃ§Ã£o')
ylabel('AcÃ§Ã£ode controlo'), xlabel('Amostra')
```

treino_modelo.mat

```
clc, clear all, close all

Nhmax = 8;
Nsimax = 3;
Ny = 1;

load dataset_prof.mat

Le = length(Ye);
Lv = length(Yv);
Unet_e = [Ye(1:Le-1) Ue(2:Le) Ue(1:Le-1)];
%Unet_e = [Ye(2:Le) Ue(2:Le) Ue(1:Le-1)]; PQ NAO ISTO
Ynet_e = Ye(2:Le);

Unet_v = [Yv(1:Lv-1) Uv(2:Lv) Uv(1:Lv-1)];
Ynet_v = Yv(2:Lv);

[trash, Nu] = size(Unet_e);
minu = min(min(Unet_e));
maxu = max(max(Unet_e));


for Nh = 1:Nhmax
    clc
    Errosq = 10e10;
    Netid = ['Net_Nh' num2str(Nh)];
    for Nsim = 1:Nsimax
        net = newff(ones(Nu,1)*[minu maxu], [Nh Ny]
,{'tansig','purelin'}, 'trainlm' );
        net = init(net);
        net.biasConnect   = [ 1 0]';
        net.performParam.ratio = 0.5; % RegularizaÃ§Ã£o
        net.trainParam.epochs = 400;
        net.trainParam.show = 100;
        net.trainParam.goal = 1e-5;
        net.performFcn = 'sse';
        net.trainParam.mu_max = 1e15;

        [net,tr] = train(net,Unet_e',Ynet_e');
        Ynn  = sim(net,Unet_v')';

        erro = (Yv(2:end) - Ynn);
        SEQ = erro' * erro;

        if SEQ <= Errosq
            Errosq = SEQ;
            eval([Netid ' = net']);
        end

    end
    eval(['save Nets\' Netid '.mat net']);
    Sum_sq(Nh) = Errosq;
end

idoptinet = find(Sum_sq <= min(Sum_sq));
```

```
netopt = ['Net_Nh' num2str(idoptinet)];
eval(['load Nets\' netopt '.mat']);
%Ynn  = sim(net,Unet_v')';
save('Nets\net.mat', 'net', '-mat', '-v7.3')

Ynn  = sim(Net_Nh3,Unet_v')';

figure(1)
plot(Yv, 'b'), hold on, plot(Ynn, 'r'), hold off
title('validation performance'), xlabel('Sample')

figure(2)
bar(Sum_sq), title('Sum of square error')
xlabel('Number of hidden layer neurons')
clear Net_*
delete Nets\Net_*
```

treino_controlador.mat

```
clear all, close all, clc

load('dataset_prof.mat') % PCT 37-100 (Processo TÃ©rmico)

Nsimax = 5;
M = length(Ue);
Unn = [Ye(2:M) Ye(1:M-1) Ue(1:M-1)]'; % 3 Entradas
%Unn = [Ye(1:M-1) Ue(2:M)]'; % 3 Entradas
Uvv = Uv(2:M);
Utrain = Ue(2:M); % Target
[Nu, trash] = size(Unn); % NÃºmero de entradas
Ny = 1; % NÃºmero de saÃ-das

%OOOOOOOOOOOOOOOOOO Topologia da Rede Neuronal

Nh = 3;
minu = min(min(Unn));
maxu = max(max(Unn));


%OOOOOOOOOOOOOOOOOO ConstruÃ§Ã£o da Rede Neuronal

disp('_____ ConstruÃ§Ã£o da Rede...')


for Nsim = 1:Nsimax
netc = newff(ones(Nu,1)*[minu maxu], [Nh Ny] ,{'tansig','purelin'},
'trainlm' );

netc = init(netc);

netc.biasConnect   = [ 1 0]';
netc.performParam.ratio = 0.5; % RegularizaÃ§Ã£o
netc.trainParam.epochs = 400;
netc.trainParam.show = 100;
netc.trainParam.goal = 1e-5;
netc.performFcn = 'sse';
netc.trainParam.mu_max = 1e15;

%OOOOOOOOOOOOOOOOOO Treino da Rede Neuronal
clc
disp('_____ Treino da Rede...')
disp('Â ')

[netc,tr] = train(netc,Unn,Utrain');

end

W1=netc.IW{1,1};
W2=netc.LW{2,1};
B1=netc.b{1,1};

%OOOOOOOOOOOOOOOOOO SimulaÃ§Ã£o da Rede Neuronal (Conunto de treino)
```

```
Unn = [Yv(2:M) Yv(1:M-1) Uv(2:M)]'; % 3 Entradas
Ynn  = sim(netc,Unn);
Errs = (Utrain - Unn')' * (Utrain - Unn')


plot(Uvv,'b');
hold on
plot(Ynn,'r');
%eval(['load NetsC\' netopt '.mat']);
save('NetsC\netc.mat', 'netc', '-mat', '-v7.3')
```

ControladorInversoDireto.mat

```
clear all, close, clc
load ('Nets\net.mat')
load ('NetsC\netc.mat')

W1c=netc.IW{1,1};
W2c=netc.LW{2,1};
B1c=netc.b{1,1};

Ref = zeros(750,1);
Ref(1:150) = 2;
Ref(150:300) = 4;
Ref(300:450) = 3;
Ref(450:600) = 4.5;
Ref(600:751) = 3;

Ts = 0.08;
a = 0.4;

Nmax=length(Ref);
u =zeros(Nmax,1);
uf=zeros(Nmax,1);
y = zeros(Nmax,1);
erro = zeros(750,1);

usbinit();
disp('Em modo controlo!')

for index = 2:length(Ref)-1
    y(index,1) = usbread(0);
    erro(index,1) = y(index,1) - Ref(index,1);

    tic
    if index <=2
        u(index,1) = Ref(index);
    else
        %u(index,1) = sim(netc, [Ref(index+1), y(index,1), u(index-
1,1), u(index-2,1)]');
        u(index,1) = W2c * tanh (W1c * [Ref(index+1), y(index,1),
u(index-1,1)]' + B1c);
    end
    uf(index,1) = a * uf(index-1,1) + (1-a) * u(index-1,1);
    uf(index,1) = max(min(uf(index,1),5),0); % SaturaÃ§Ã£o da
excitaÃ§Ã£o
    usbwrite(uf(index),0)
    Dt = toc;
    pause(Ts-Dt)
 end
 usbwrite(0,0)

 erro = sumsqr(erro);

 subplot (2,1,1), plot (y(1:749)), hold on, plot (Ref(1:749)), hold
off
 save expdataDI.mat Ref uf y -mat
```

ControladorIMC.mat

```
clear all, close, clc
load ('Nets\net.mat')
load ('NetsC\netc.mat')


W1c=netc.IW{1,1};
W2c=netc.LW{2,1};
B1c=netc.b{1,1};

W1=net.IW{1,1};
W2=net.LW{2,1};
B1=net.b{1,1};


Ref = zeros(750,1);
Ref(1:150) = 2;
Ref(150:300) = 4;
Ref(300:450) = 3;
Ref(450:600) = 4.5;
Ref(600:750) = 3;

Ts = 0.08;
a = 0.4;

Nmax=length(Ref);
u =zeros(Nmax,1);
uf=zeros(Nmax,1);
y = zeros(Nmax,1);
erro = zeros(750,1);

usbinit();
disp('Em modo controlo!')

for index = 2:length(Ref)-1
    y(index,1) = usbread(0);

    erro(index,1) = y(index,1) - Ref(index,1);

    tic
    if index <=2
        u(index,1) = Ref(index);
    else
        %ym = sim(net,[y(index-1,1), uf(index-1,1), uf(index-2,1)]');
        ym =  W2 * tanh (W1 * [y(index,1), uf(index,1), uf(index-
1,1)]' + B1);
        epsilon = y(index,1) - ym;
        %u(index,1) = sim(netc, [Ref(index+1)-epsilon, y(index,1),
u(index-1,1), u(index-2,1)]');
        u(index,1) = W2c * tanh (W1c * [Ref(index+1), y(index,1),
u(index-1,1)]' + B1c);
    end

    uf(index,1) = a * uf(index-1,1) + (1-a) * u(index-1,1); %filtro
passa baixo
```

```
    uf(index,1) = max(min(uf(index,1),5),0); % SaturaÃ§Ã£o da
excitaÃ§Ã£o
    usbwrite(uf(index),0)
    Dt = toc;
    pause(Ts-Dt)
end

erro = sumsqr(erro);

 usbwrite(0,0)
 save expdataIMC.mat Ref uf y -mat
```

ARXvsNN.mat

```
%comparacao da rede neuronal utilizada com o modelo arx do primeiro
%trabalho

load ('Nets\net4.mat')
load('dataset_prof.mat') % PCT 37-100 (Processo TÃ©rmico)

Nmax = length(Uv) - 1

%ARX(3,1,2)
A = [ 1 -1.504 0.8344 -0.2358 ];
B = [ 0 0 0.1037];

y = zeros(length(Uv),1);
yNN = zeros(Nmax,1);
erro = zeros(length(Uv),1);
erroNN = zeros(length(Uv),1);

for index = 3:Nmax
    y(index+1,1) = -A(2)*y(index,1)-A(3)*y(index-1,1) -A(4)*y(index-
2,1) + B(1)*Uv(index,1) + B(2)*Uv(index-1,1) + B(3)*Uv(index-2,1);
    erro(index+1) = y(index+1,1)-Yv(index+1,1);
end

for index = 3:Nmax
    yNN(index) = sim(net,[yNN(index-1,1), Uv(index-1,1), Uv(index-
2,1)]');
    erroNN(index+1) = yNN(index,1)-Yv(index,1);
end

errosqrARX=sumsqr(erro)
errosqrNN=sumsqr(erroNN)

plot ( 1,1), plot (y(1:Nmax),'r'), hold on, plot (Yv(1:Nmax),'b'),
plot (yNN(1:end),'g'), hold off
```

Bibliografia utilizada

slidesNN-2020.vrs2.pdf, Departamento de Eng. Electrotécnicae de Computadores (versão 2020)